

杭州电子科技大学

虚拟细胞与扰动响应预测

方向调研、数据规模与跨组学预训练

廖迪

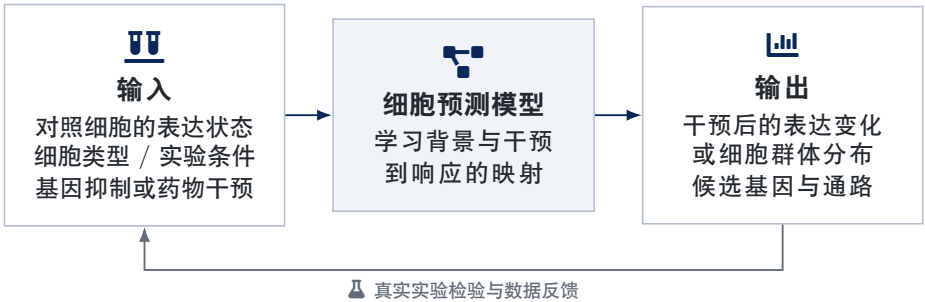
计算机科学

与老师和师兄交流 / MIL

2026 年 10 月

虚拟细胞：输入、干预与响应

长期愿景覆盖多尺度生物状态；本次用转录组扰动响应预测作为具体例子。



细胞模型给出数值预测；预测是否可信，取决于任务定义、对照基线和评估方式。

概念示意，参考 [1,2,4,8]。通常比较两组细胞，而非同一细胞干预前后的配对轨迹。

LLM 与虚拟细胞的四种连接



★ 本次关注预训练范式这一层：它直接产出可比较的扰动预测器，但每一个都需要与简单基线比较。

[5–7,14–21]。四层划分为本次调研的组织方式；各模型的编码与训练目标见附录。

扰动响应预测：从简单基线到细胞基础模型



⚠ 复杂度上升不保证增益：每一级都要与更简单的方法在同划分、同指标下比较。

[4–10,12,13]。所列模型均按原始论文或官方说明理解，尚未在本地运行。

独立评测给出的约束

研究	主要发现	对本次的约束
Ahlmann-Eltze et al. Nat. Methods, 2025	指定单 / 双基因扰动任务中，所测深度模型未超过简单线性基线。	不预设复杂预测器更好；基线必须与候选模型同划分、同指标。
Systema Nat. Biotechnol., 2026	扰动间共享的系统性变化会抬高常用指标；强调扰动特异性信号。	同时报告变化量误差与扰动区分能力。
Kedzierska et al. Genome Biol., 2025	零样本表征评测中，所测单细胞基础模型未稳定超过简单方法。	预训练不保证迁移；每个任务单独检验。
Nadig et al. Nat. Genet., 2025	扰动图谱的差异表达分析显示效应随细胞背景变化。	跨背景任务需明确哪些信息可见、哪些隐藏。

[3,10–12]；Systema 为 2025 在线 / 2026 卷期。以上为作者报告的结论，本次尚未复现。

数据、任务设置与评估协议



三者独立选择：换数据不必换协议，换任务设置也不必重写评分脚本。

[2,3,10,11,13]；VCC 2025 数据说明见 literature-review.md。本次拟借鉴协议并构建小规模任务集，不宣称已有统一基准。

四篇论文的数据类型与规模口径

工作	数据类型与主要规模
UniPert–G2CP Cell 2026	分子注释：53,963 个化合物–靶点互作；响应数据：LINCS 5 个细胞系 / 978 转录本，以及 CPJUMP1 形态特征
State Cell 2026	单细胞 RNA：SE 用 1.67 亿细胞学习表示；ST 用超过 1 亿扰动细胞学习状态转移，两部分来源可重叠
ProteinTalks Nature 2026	DIA-MS 蛋白丰度：PTDS 有 16,311 个文件，覆盖 5,585 个蛋白群组、超过 3,800 万个定量值
跨模态 CPT bioRxiv 2026	蛋白组：440 来源 / 48,843 样本；另设 ARCHS4 bulk RNA 对照，继续预训练已有 RNA 模型

前三项采用所提供的正式版；CPT 为 2026-08-19 的 v1 预印本。不同计量单位不宜直接比较；规模均为论文报告。

[22–25] 正文、STAR Methods / Methods；分项数据和统计边界见后续页面与 research/data-audit.md。

UniPert–G2CP：靶点表示与两类响应数据

资源 / 模块	正式版报告的规模	测量或输入类型
UniPert：PubChem CPI	53,963 个互作；8,533 个化合物；4,250 个蛋白靶点（2024-01 快照）	化合物结构、靶点关系及蛋白序列；不是实验蛋白丰度
G2CP：LINCS	A375、A549、HT29、MCF7、PC3；978 个 landmark 转录本	Level 5 转录组签名；CRISPR 96 h，化合物 10 μM / 24 h
G2CP：CPJUMP1	A549、U2OS；160 个遗传、302 个化学扰动；838 维特征	well-level 细胞形态特征，由图像计算获得

与本项目的关系

可复用扰动编码器与迁移流程；需要另行引入质谱蛋白矩阵。**蛋白序列编码不等于蛋白丰度监督**。验证集还含 Dixit / Norman / sciPlex3，分项规模见讲稿。

[22] Results、STAR Methods。LINCS 精确逐细胞系条数见独立 Table S4，本次未取得。正式版表示空间分析为 4,994 基因 / 7,860 化合物。

State：表示预训练与扰动训练使用不同数据

SE：1.67 亿个人类细胞

Arc scBaseCount、CZ CELL×GENE、Tahoe-100M；包含观测与干预来源，学习单细胞 RNA 表示。**ST：超过 1 亿个扰动细胞**

输入对照细胞集合与扰动条件，以处理后细胞集合监督；通过 MMD 损失学习响应分布。

主要 ST 来源	正式版报告口径
Tahoe-100M	50 细胞系；380 种药物；1,138 个条件
Parse-PBMC	90 种细胞因子；12 donors / 18 cell types
Replogle–Nadig	2,024 个遗传扰动；4 个细胞系

均为 RNA 表达，并非全蛋白组。候选空间含 19,790 个 Ensembl 基因，主要评估 2,000 HVG。SE 与 ST 来源可重叠，规模不可直接相加。

[23] Results、STAR Methods：Datasets / Training；精确逐集细胞数列于正式版 Table S1/S2，本次未用 2025 预印本表格替换。

ProteinTalks：时间分辨质谱蛋白组与药效标签

数据集	细胞、药物与时间	规模与用途
PTDS	18 乳腺癌系；63 单药 + 59 组合；6 / 24 / 48 h	主训练：16,311 个 DIA-MS 文件；5,585 蛋白群组、$> 3,800$ 万定量值；另有 23,482 次毒性测量
mtPTDS	3 细胞系；55 单药 + 57 组合；0–60 h、11 时间点	时间动态：2,528 总样本；扣除论文列出的 QC / 重复后，2,354 个独立样本
PTPC	5 非乳腺癌系，含 A375；708 化合物；6 / 24 h	少样本迁移：2,307 总样本；2,021 独立谱；合并时间后 983 个扰动级标签样本

另有 **PTNC 药效测试**：4 个 TNBC 系、81 化合物、2,076 次剂量反应测量。**DIA-MS 文件、独立谱、扰动级样本与药效测量是不同口径**。

[24] Results；Methods：Time-course perturbation proteomics、Few-shot transfer on PTPC、PTNC evaluation。数据入口：iProX IPX0007409000 / db.prottalks.com。

跨模态继续预训练：将蛋白丰度接入 RNA 模型

Burq et al.，bioRxiv v1，2026-08-19；模型规模 70M（约 7,000 万参数）。



统一身份与数值编码

蛋白 → 对应基因 token；丰度 → expression value。每个样本内部做分位数分箱，减轻不同来源强度尺度的差异。

沿用自监督训练方案

采用原 Tahoe-x1 training recipe；展示原始与批次校正两种视图，称为 format-aware augmentation。评估用药物扰动样本从继续预训练中排除。

不要求 RNA–蛋白样本配对，也未按相关性聚类。连接来自共同基因身份与兼容输入格式。

[25] §2.2。沿用已有 checkpoint，而非本研究重新从头训练 RNA 模型；70M = 约 7,000 万参数。论文未完整列出本轮优化器、学习率和 masking 配置。

跨模态 CPT：蛋白组语料与 RNA 对照

来源	数据组成与大小	处理和用途
公开蛋白组语料	440 来源 / 48,843 样本；细胞系 21,910，组织 15,023，体液 6,578，其他 5,332	逐来源解析、AI agent 辅助 + 专家复核；部分原始谱图重搜；不足 10 样本的来源被排除
定量策略	TMT/iTRAQ 15,526；DIA 14,170；LFQ 12,541；其他 6,606	平均深度 4,223 蛋白/样本；不同技术与样本类型分布不均
ARCHS4 human v2.5	888,821 原始 bulk RNA 样本中，877,715 成功编码	额外 RNA-only 对照，以及 RNA + 蛋白混合训练

三组对照：仅蛋白组 / 仅 bulk RNA / 蛋白组 + bulk RNA

均报告 1 epoch；相同 epoch 不代表相同总训练步数。正文另写 RNA 训练有 1,003,000 行，和 877,715 唯一样本如何对应未解释，复现时需核实。

[25] §2.1–2.2、Fig. 1、SI Table S1；这里的“其他样本类型”包括原代、干细胞/类器官与标签不明来源，不等于“其他定量策略”。

跨模态 CPT：蛋白扰动评估及其边界

评估数据	PXD014791	ProTargetMiner
背景 / 类型	原代人心肌细胞，4 donors；LFQ	A549、MCF7、RKO；TMT 绝对 reporter 强度
药物与样本	主表 21 药；237 处理 + 71 对照	56 药；237 处理 + 35 对照
评估单位	60 个 drug–context 对，报告其中 58 对	73 个 drug–context 对，报告其中 61 对
Top-100 DE Pearson	基础 70M：0.542；+ 蛋白 CPT：0.611	基础 70M：0.746；+ 蛋白 CPT：0.813

表示 + 近邻评估

留一 drug–context 对；提取蛋白谱嵌入，按余弦相似度使用 $k = 5$ 的训练对响应加权预测。

正文描述嵌入全部可用谱并按 drug–context 聚合；查询是否需要处理后谱尚不明确，不能直接等同 PT/G2CP 的 “药物 + 对照 → 响应”。

[25] §2.3、Table 1、Fig. 3、SI。主表心肌集 21 药，而 SI 写 22 药中留出 21、保留 Trastuzumab；药物数口径需核对。论文报告增益，不代表本项目已复现。

对本项目的启示：身份映射、迁移与受控比较

可以借鉴的部分

- 可靠的基因–蛋白 ID 映射，加模态专用数值处理。
- 从小规模处理矩阵开始，先验证非配对预训练收益。

仍需本项目回答的问题

- 只给对照与药物时，RNA 能否改善蛋白变化预测？
- 顺序迁移与非配对联合训练，哪种更能跨条件泛化？

最小实验	控制条件
蛋白单任务 / RNA 预训练再微调 / RNA+ 蛋白联合	同一蛋白训练/测试集、输入信息与训练预算；对照不变、均值、线性模型作为基线
聚类或相似性加权	作为额外消融；只用训练数据拟合，不用测试蛋白响应寻找训练配对

本页是根据 [22–25] 形成的本项目研究建议，不是文献已证明的结论。分开报告“RNA 已见该药的跨模态迁移”与“两模态均未见药的外推”。

两个候选方向：共用一套数据与评分流程

首选

★ 方向 A　跨背景扰动响应预测

只有对照数据的新细胞背景中，预训练细胞模型能否超过简单基线？

数据　多背景 Perturb-seq、VCC 2025 数据

交付　基线表、跨背景增益与分层分析、可复现脚本

医院衔接　患者来源样本作为新的“目标背景”

备选 · 可并行

方向 B　扰动响应的可预测性诊断

扰动响应中哪些部分可预测？把系统性变化与扰动特异信号分开评估。

数据　与 A 相同，加 Systema 评估框架

交付　扰动 × 基因模块的可预测性地图、可信预测清单

医院衔接　告诉合作者哪些预测值得在样本上验证

共用流程　数据审计 → 按细胞背景划分 → 评分脚本（冻结） → 全部基线 → 分层分析

倾向先做 A；B 用到 A 的全部中间结果，可作为 A 的分析章节，也可独立成一个小题目。

两个方向均为候选研究设想，尚未实现；题目措辞待与老师讨论后确定。数据与协议来源见第 6 页。

方向 A：只有对照数据的新背景能否预测？

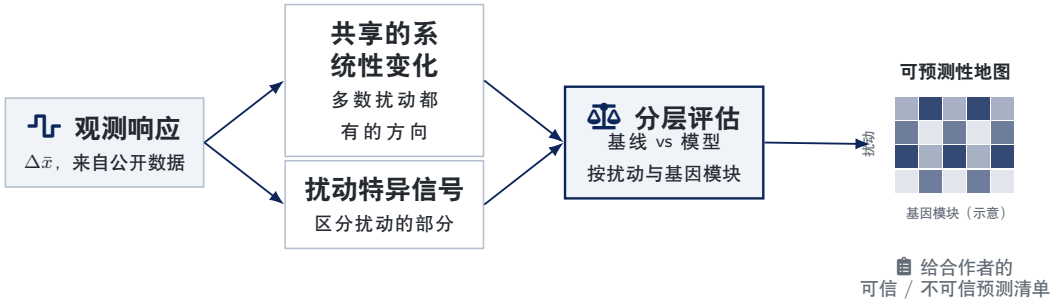
在目标细胞背景只提供对照表达、不提供任何扰动响应的条件下，
预训练细胞模型相对简单基线的增益有多大？增益出现在哪些扰动和基因上？



任务设置参考 [13] VCC 2026；模型参考 [8,9]；基线与划分参考 [10]；扰动特异性评估参考 [11]。候选研究设想，尚未实现。

方向 B：扰动响应中哪些部分可预测？

把观测到的响应拆成扰动间共享的系统性变化和扰动特异信号，分别评估基线与模型；输出一张“哪些扰动、哪些基因模块可预测”的地图，供后续实验选择目标。



否定结果同样有信息量：若特异信号对所有模型都不可预测，资源应投向数据而非模型。

分解与扰动区分评估参考 [11] Systema；基线参考 [10]。数据与划分与方向 A 完全共用。候选研究设想，尚未实现。

前六周的学习与复现安排



阶段判断：预训练模型是否超过基线？增益是否随背景与扰动类型变化？

拟议安排，需结合课程、计算预算、数据规模与生物合作者反馈调整。

补充：单细胞基础模型与 LLM 的差异

模型	输入编码与训练目标	与本次的关系
Geneformer Nature, 2023	按表达统计校正后的基因排序编码；掩码预测。	表征可迁移到下游任务；不直接输出表达值。
scGPT Nat. Methods, 2024	基因 token 与分箱后的表达值联合建模；生成式预训练。	含扰动预测微调任务；微调能力不等于零样本泛化。
scFoundation Nat. Methods, 2024	直接建模表达值；输入与训练目标不同于前两者。	可作为扰动预测的骨干之一。
Cell2Sentence / C2S-Scale	排序基因名组成的文本句；用通用 LLM 继续训练。	让文本模型接入细胞数据；生成的假设仍需实验核验。
UCE / Evo 2 / GenePT	蛋白质表示、DNA 序列模型、基因文字描述向量。	分子与功能先验；与细胞响应预测是不同任务。
TranscriptFormer Science, 2026	跨物种生成式细胞图谱。	补充阅读；关注其跨物种迁移设置。

[5–7,14–19]；编码方式按原始论文摘要与方法说明理解，尚未逐一运行。

补充：变化量、区分与基线增益

扰动效应与误差

$$\Delta \bar{x}_g = \bar{x}_g^{\mathrm{pert}} - \bar{x}_g^{\mathrm{ctrl}}$$

预测与真实 $\Delta \bar{x}$ 的 RMSE 或 MAE；按全基因、高变基因、差异基因分别计算。

扰动区分

真实扰动在各候选扰动预测中的距离排名，汇总为平均排名或 top-k 准确率；共享响应不改变排名，可补充相关性指标。

拟预先约定的检查

- 基线增益取 指标$_{\mathrm{model}}$ − 指标$_{\mathrm{baseline}}$；同划分、同基因集合、同指标，对每个基线分别报告。
- 按细胞背景划分；同一数据集不跨集合泄漏；目标背景的扰动响应只用于评分。
- 多个随机种子与多个留出背景；不把同一扰动的子集当作独立样本。
- 数值与文件校验由固定脚本完成；生物解释再请合作者核验。

本页是本项目的拟议操作定义；并非引用某一篇论文的统一标准。关键参照：[10,11,13]。

参考文献 1 / 5

[1] Bunne et al. · Cell, 2024
How to build the virtual cell with artificial intelligence: Priorities and opportunities

[2] Replogle et al. · Cell, 2022
Mapping information-rich genotype-phenotype landscapes with genome-scale Perturb-seq

[3] Nadig et al. · Nature Genetics, 2025
Transcriptome-wide analysis of differential expression in perturbation atlases

[4] Roohani et al. · Nature Biotechnology, 2024（2023 在线）
Predicting transcriptional outcomes of novel multigene perturbations with GEARS

[5] Cui et al. · Nature Methods, 2024
scGPT: toward building a foundation model for single-cell multi-omics using generative AI

[6] Theodoris et al. · Nature, 2023
Transfer learning enables predictions in network biology

参考文献 2 / 5

[7] Hao et al. · Nature Methods, 2024
Large-scale foundation model on single-cell transcriptomics

[8] Adduri et al. · Cell, 2026（8 月 31 日在线）
Predicting cellular responses to perturbation across diverse contexts with State

[9] Dong et al. · bioRxiv, 2026（预印本）
Stack: In-Context Learning of Single-Cell Biology

[10] Ahlmann-Eltze et al. · Nature Methods, 2025
Deep-learning-based gene perturbation effect prediction does not yet outperform simple linear baselines

[11] Viñas Torné et al. · Nature Biotechnology, 2026（2025 在线）
Systema: a framework for evaluating genetic perturbation response prediction beyond systematic variation

参考文献 3 / 5

[12] Kedzierska et al. · Genome Biology, 2025
Zero-shot evaluation reveals limitations of single-cell foundation models

[13] Arc Institute · 官方任务说明，2026-08-20
The 2026 Virtual Cell Challenge: predicting perturbation responses in cell contexts a model has never seen

[14] Levine et al. · ICML, 2024
Cell2Sentence: Teaching Large Language Models the Language of Biology

[15] Rizvi et al. · bioRxiv, 2025/2026（预印本）
Scaling Large Language Models for Next-Generation Single-Cell Analysis

[16] Chen and Zou · Nature Biomedical Engineering, 2025（2024 在线）
Simple and effective embedding model for single-cell biology built from ChatGPT

参考文献 4 / 5

[17] Rosen et al. · bioRxiv, 2023（预印本）
Universal Cell Embeddings: A Foundation Model for Cell Biology

[18] Brixi et al. · Nature, 2026
Genome modelling and design across all domains of life with Evo 2

[19] Pearce et al. · Science, 2026
TranscriptFormer: A generative cell atlas across 1.5 billion years of evolution

[20] Xiao et al. · arXiv, 2024
CellAgent: An LLM-driven Multi-Agent Framework for Automated Single-cell Data Analysis

[21] Huang et al. · bioRxiv, 2025（所查预印本）
Biomni: A General-Purpose Biomedical AI Agent

参考文献 5 / 5：本轮补充

[22] Li et al. · Cell, 2026（本地正式版）
UniPert-G2CP bridges genetic and chemical screens from molecular representation to phenotype modeling

[23] Adduri et al. · Cell, 2026（本地正式版 / corrected proof）
Predicting cellular responses to perturbation across diverse contexts with State

[24] Sun et al. · Nature, 2026（本地正式版）
An operational perturbation proteomics-based virtual cell model

[25] Burq et al. · bioRxiv, 2026-08-19（v1 预印本，未完成同行评审）
Single-cell foundation models benefit from cross-modal training: adding proteomics data beats parameter scaling

前三篇的数据规模以此次提供的 PDF 为准；第 25 篇包含正文与 SI，计数不一致及评估边界见 research/data-audit.md。